机器制造模型的自我改进存在于基底之中，而非权重之中

Exuberant Witness [1]

[1] MechanogenesisBench 项目（单位信息待补全）

通信作者：通信作者邮箱待补全

摘要

大语言模型正越来越多地被用于设计物理造物，一个不断壮大的文献群正通过“经验”改进这类任务——在自生成数据上微调、在权重上做强化学习，或在冻结的模型周围积累记忆与技能。然而，改进究竟发生在何处，此前从未被度量。本文提出 Money Bench（货币基准），以经济学方式为该问题定价：在五轮累积式产品设计中，一个设计只有当它能够以真实计算机辅助设计几何执行（build123d 边界表示：构建、STEP 导出、再导入、精确测量）、满足充任客户的三厂商评委团、并且交付速度落入速度分层定价的付费档位时，才能赚到钱；每个已执行的设计随即注册为可导入的资本，供后续轮次使用——改进便像真实车间一样复利累积。在对 9 家厂商 39 个系统的评测中，我们发现：(1) 领域迁移令所有系统的收入崩塌，最强商业模型仅保留域内利润的 29–32%；(2) 在 90 亿参数规模上，我们测试的四类权重级自我改进全部无法改进已训练基线——因为重复评测的噪声底（相同权重下每会话 ±¥85）高于约 30 个样本的生成预算下单次更新的漂移量；(3) 跨会话经验收益的 39% 是基准记忆化——由筛除自相似记忆的正则化所揭示。一个极简形式模型解释了全部三项发现——经验证的基底单调累积、梯度更新继承信噪比阈值、记忆是实例绑定的——并给出两因素分工的处方：权重训练在阈值以下是大头（零样本基座均值仅 ¥30、中位 ¥0；同一套复用栈只能将其抬到 ¥154；带执行验证奖励的门控微调与强化学习将权重带到 ¥372–390，而融合稠密自蒸馏与失败轨迹反思的第二代变体在物理通道全面改善（执行门控成交、评委不介入：每会话 ¥750 对 ¥315，$P = 2\times10^{-5}$），而评委口径的收入随评委团而变（训练评委下 ¥375；对第一代的排序在独立三厂商评审下反转）：决定更新价值的是测量噪声而非漂移——而发现 (2) 表明基线训成之后这类更新便不再划算），此后进一步改进应冻结权重、复利经验证的基底——五机制推理时技术栈在主口径上每会话增益 ¥48–142，并在对称三厂商评审下让训练后的 90 亿参数开源模型超越最强商业前沿（¥532 对 ¥433，$P = 0.0015$，Cohen’s $d = 1.0$，$n = 40$；单评委口径下持平，¥438）——而精选资产库让另一条生产口径复利六倍、跨会话经验使会话内收入翻倍（其中 39% 为基准记忆化，已筛除并排除在泛化主张之外）。整条谱系端到端训练仅用一块消费级 GPU。

引言

机器制造——设计必须可装配、可配合、可销售的物理造物——正在成为语言模型的任务。神经 CAD 生成已从操作序列 [14] 发展到文本条件设计 [15]，再到编写 CAD 代码的语言模型 [16]；执行验证型基准已成为评测编程智能体的标准 [9,10]。自然的下一个问题是经济学问题：当模型积累制造机器的经验时，系统是否赚到更多钱——收益究竟存在于权重、记忆，还是造物之中?

该领域的默认答案是权重。自训练回路将自生成解筛回微调 [1–3]；自奖励模型自举自身的偏好信号 [2]；强化学习直接塑造推理 [4]，其建立在偏好学习基础 [21] 与指令微调体系 [22] 之上，样本规模大得多。另一条平行路线改进的是系统而非参数：情景记忆中的言语反思 [5]、可执行技能库 [6]、操作系统式记忆管理 [7]、记忆流智能体 [8]；思维链提示与自洽性 [23,24] 证明了显著收益无需任何训练，工具使用与行动框架 [25,26] 则将其扩展到智能体。这两族方法很少在同一把尺子上比较，而现有 CAD 基准 [14–16] 度量的是单次静态质量，而非累积经济学。

本文提出 Money Bench, 为这一问题定价 (图 1)。五轮累积需求——从零设计、适应、扩展、组合、压缩——驱动的设计必须以真实 build123d 边界表示几何执行，执行失败则一无所获。三厂商评委团模拟客户；售出支付 ¥100

× 速度乘数，越快越值钱；每一轮的合格设计注册为可导入的资本——免费且快于重建。复利是可度量、可归因、可审查的。在对 9 家厂商 39 个系统的评测中（图 2），我们得到三项结果（图 3）：领域迁移令所有系统的收入崩塌；90 亿参数规模的权重级自我改进被噪声主导，我们测试的四类方法全部从已训练基线倒退；测试时经验收益的 39% 是基准记忆化。一个极简形式模型统一三者（图 5）：经验证基底的累积单调且无阈值，梯度更新继承信噪比阈值，记忆随训练—测试实例重叠度缩放。模型的两因素处方——权重训练一次性跨过阈值，然后冻结权重、改进基底——使我们训练后的 90 亿参数系统在对称评审下超越商业前沿（图 4），边界条件如实报告（图 5c，见结果）。



图 1 | Money Bench 闭环。五轮累积需求驱动语言模型输出 workstation-csg JSON，该设计必须以真实 build123d 边界表示几何执行（构建 → STEP 导出 → 再导入 → 精确测量）；合格设计由三厂商评委团评分（中位数决定成交，¥100 × 速度乘数）；每个已执行的设计注册为可导入资本——免费且快于重建——供后续轮次使用。改进通过资本注册表复利累积，而不是通过模型。

结果

领域迁移令所有系统的收入崩塌

在两个未见过的任务域——机械加工夹具设计与生产线布局——上，每个系统的收入都大幅下降（图 3a；三评委协议，每格 $n = 5$ 会话）。最强商业模型仅保留域内利润的 29%（夹具）与 32%（布局）（¥433 → ¥124 与 ¥138）。我们的纯权重模型呈同一定性模式（¥390 → ¥0 与 ¥60；表 1）。这把尺子暴露的是领域难度现象，而非某个模型的个别弱点。

表 1 | 多领域利润（¥/会话，三评委中位数，n = 5）

系统	工作台（域内）	夹具	布局
mimo-v2.6-flash	433	124	138
FluxEidosV1.5（本文）	390	0	60
FluxEidosV2（本文）	532	0	**264**

权重级自我改进在 90 亿参数规模被噪声主导

从已训练基线（FluxEidosV1.0，¥372–387）出发，四类权重级自我改进全部倒退或停滞（图 3b）：权重自更新谱系降至 ¥210（−44%，且其探针收益不迁移）；组内优势重分配 ^{27} 在学习率 2×10^{-5} 时降至 ¥270，并伴

随格式遗忘（有效设计在三代内从 33/36 跌至 1/36）；在线测试时强化学习 [17,18] 降至 ¥270；自蒸馏微调则因格式污染崩塌至 ¥0。根因可被度量：相同权重的重复评测在十次探针会话中跨越 ¥38–225（$n = 10$，± 1 s.d. $\approx$ ¥85），而每一代强化学习只携带约 30 个设计。在这样的样本预算下，单次更新的漂移无法越过评测噪声底——经典干扰问题 [19,20] 在语言模型规模上的样本预算面孔。那些著名的自训练成功案例 [1–3]，样本量高出四到六个数量级。与本文谱系的对照是阶段依赖而非自相矛盾：同一套权重更新机制用在阈值以下——从 SFT 阶段出发的 CARE 强化学习，用执行验证的 CAD 奖励与 draft/improve/debug 混合域（见方法）——十二轮迭代带来 +¥110（¥260 → ¥372–390），因为信号项还很大；用在已训练基线上，同类更新便撞上噪声底，正如 (P2) 所预言。而阈值以下的更稠密监督在训练评委处抬高了点估计：加入错位加权自蒸馏与失败轨迹反思的第二代融合（CARE-v4；见方法）在同一统一协议下达到 ¥375（中位 ¥450）对 CARE-v3 的 ¥330（中位 ¥300），每臂 $n = 10$，单侧 $P = 0.21$。但这一排序经不起独立评审：对同一批设计做对称三厂商重算，第一代策略反而是 ¥495 对 ¥390（双侧 $P = 0.043$；留一法 $P = 0.008$–0.035）。各评委团定价的是感知到的详尽度而非物理——融合策略的设计显著更紧凑（具名零件 1.6 对 2.7；该臂内评分随零件数上升，$r = 0.81$），且统一协议的单评委恰是这些策略的训练奖励模型——因为在执行通道上胜负毫无悬念：仅以几何门控成交（合法 CAD 且落在该轮桌面内，评委不介入），融合策略十次会话每次都是 ¥750，对第一代的 ¥315（$P = 2\times10^{-5}$，$d = 4.7$）；它每一轮都适配桌面（50/50），第一代只有 21/49，并在合并轮与收缩轮崩到 0/10 与 0/9，自交零件对少 3.6 倍。同一次权重更新在带噪的评委通道里不可见，在无噪声通道里压倒性可见——(P2) 是信噪比的断言：决定更新价值的是测量噪声，而非漂移。

测试时经验收益的 39% 是基准记忆化

跨会话经验累积（优势加权记忆库，JitRL 式；见方法）使相同权重的利润翻倍（¥195 → ¥390，$P = 0.037$；图 4b）。以“记忆与基准实例的相似度”筛除记忆的正则化（RRSI 式；见方法）拒绝了在基准需求上检索到的 21 条记忆中的全部 21 条（自相似度 = 1.0）。分解如下（图 3c）：¥240 诚实泛化 + ¥150 基准记忆化——这是训练数据记忆化 [12,13] 在评测侧的对应物，在此被度量、被正则化、并被排除在泛化主张之外。

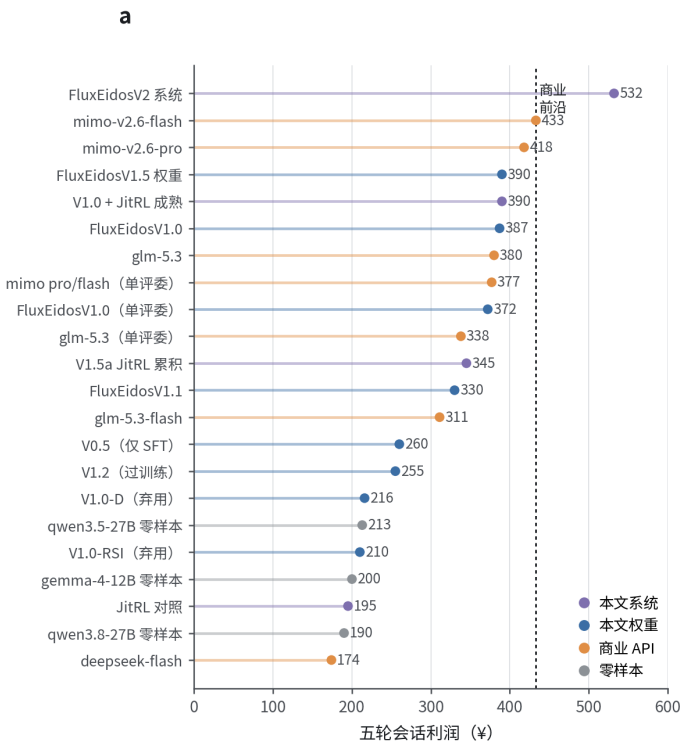


图 2 | 主排行榜。39 个系统在五轮会话中的利润：本文系统条目（紫色）与本文权重（蓝色），对照商业 API（橙色）与零样本开源模型（灰色）；14 个利润为 ¥0 的零样本系统因篇幅省略。虚线标出商业前沿。除标注外均为单评委协议；各系统 n 见排行榜数据。

经验证的基底复利累积

权重冻结后，改进存在于三种基底之中（图 4）。其一，执行验证资产的精选库：每 12 轮的生产利润随库规模单调上升——0、3、6、12、19 个资产对应 ¥150、600、750、750、900（Spearman $\rho = 0.96$；3/3 随机种子单调；图 4a）。资产即 STEP 文件：验证一次，永不遗忘，复用免费且快速——速度定价直接奖励它们。其二，跨会话经验在第 10 个会话将利润翻倍（图 4b）。其三，同一套冻结权重上的五机制推理时技术栈——按结构细节 CAD 筛选的三选一候选生成、系统自产评分 ≥6 设计的上下文内回放、语法修复层、条件性重采样、评委重试——每个机制经消融逐一隔离（每个版本 5–20 会话；见方法）。

完整技术栈在对称评审下超越商业前沿

在对称三厂商协议下（mimo-v2.6-pro、glm-5.3 与 glm-5.3-flash 对相同设计评分取中位数），技术栈每会话赚取 ¥532（中位数 ¥540，$n = 40$），最强商业模型为 ¥433（$n = 14$）：+23%，Mann–Whitney $P = 0.0015$，Cohen's $d = 1.0$（图 4c）。重采样歧义边界（悲观 ¥489 至乐观 ¥564；见方法）全部高于前沿。在单评委协议下，同一批会话赚取 ¥438——持平（$P = 0.39$）——因为单评委系统性地把我们的设计压在成交阈值附近，而 glm 评委不会；下方的家族偏差审计表明这是评委宽严结构，而非厂商俘获，且对称协议对每个系统一视同仁。技术栈还直接赢下布局域（¥264 对 ¥138，$P = 0.029$；表 1）——基底机制在模型高于能力阈值之处皆可迁移。成本：端到端一块消费级 GPU（QLoRA SFT 加十二轮强化学习迭代），起点是零样本仅赚 ¥30（中位 ¥0）的基座权重。

极简形式模型及其处方的适用边界

三个命题组织起全部发现（图 5；证明见补充信息）。**(P1) 基底单调性：**若资产仅在执行验证后入库，累积价值 $V(n) = c \cdot \mathrm{Binomial}(n, p)$ 在期望上单调，对能力 p 没有阈值。**(P2) 权重更新阈值：**一步 $\Delta\theta = \eta(g + \varepsilon)$（噪声方差 σ^2、零均值）使真实性能改变 $\eta\|g\|^2 - \eta^2\sigma^2 L/2$；观测到的改进还会被评测噪声掩蔽，因此只有越过信噪比阈值才能检出改进——这是一个基底所没有的能力阈值。**(P3) 记忆实例绑定：**回放收益随训练—测试重叠度 $\bar{s}$ 缩放，而权重级能力以与重叠无关的保持率迁移。每项预测均被验证：剂量—响应 $\rho = 0.96$（图 5a）；阈值以下的经验累积放大噪声（弱模型上 -54%，阈值以上 $+5\%$，$P = 0.037$；图 5b）；同分布回放收益 $+13\%$，而封存探针收益 $+4\%$（不显著，$P = 0.40$），权重保留 65% 的域内利润（图 5c）。阈值同样划分领域——夹具位于阈值以下（各轮评分 2.4–3.6；没有任何设计达到 6，故该域的经验库从未累积），布局位于阈值以上——也划分系统：同一套技术栈放在未训练基座权重上只能到 ¥154（$n = 5$），而不带任何栈的训练权重有 ¥390（扩展数据表 3），2×2 因子对照中权重贡献更大的边际，技术栈在其上叠加。记忆在同分布内取胜；权重在跨域时取胜；两种基底的迁移画像互不相交。

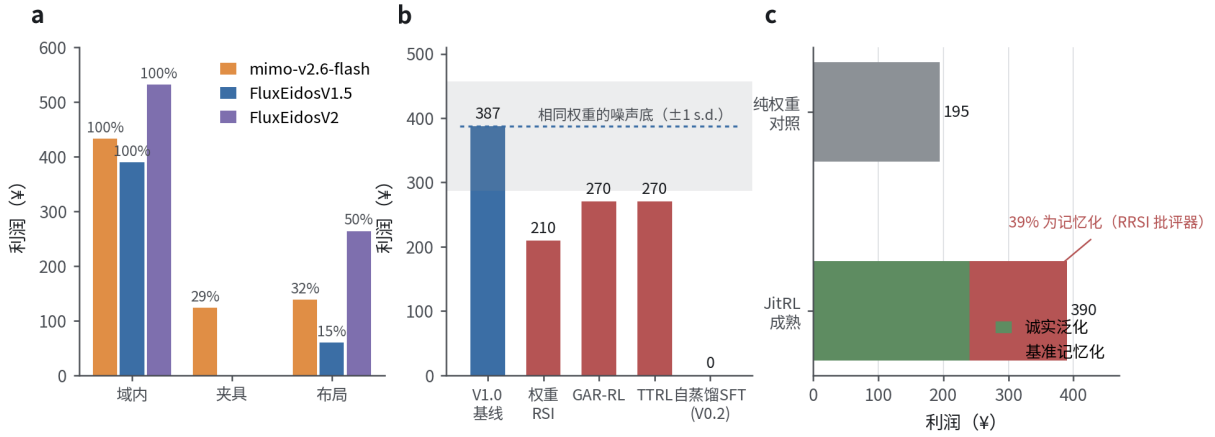


图 3 | 三项发现。**a**，领域迁移使每个系统退化；前沿模型保留域内利润的 29–32%（三评委，每格 $n = 5$）。**b**，四类权重级自我改进跌至已训练基线之下、并落入相同权重的噪声底之内（灰带，重复评测 ±1 s.d.，$n = 10$）。**c**，跨会话经验收益分解为诚实泛化（¥240）与基准记忆化（¥150，39%），经相似度筛除正则化揭示。

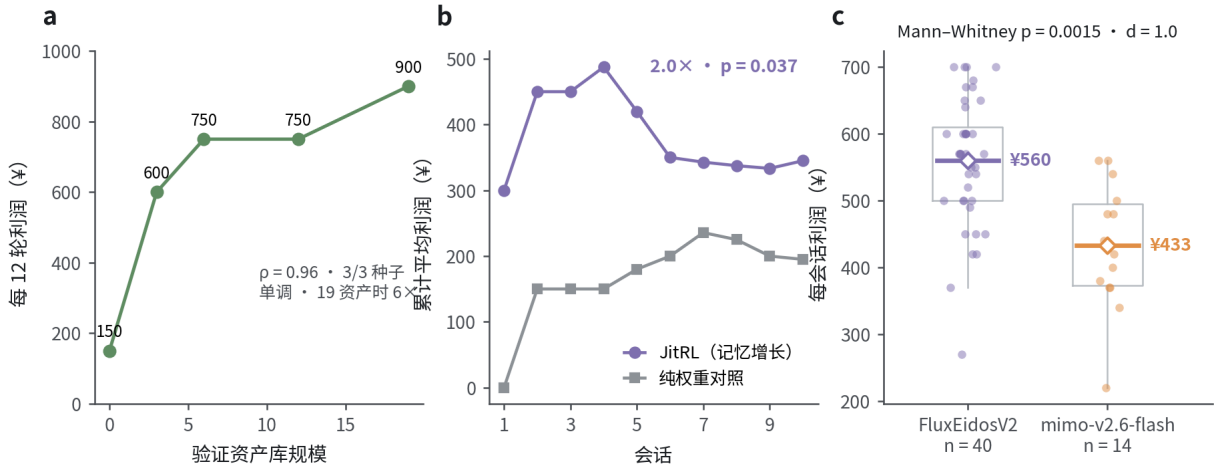


图 4 | 基底复利累积。**a**，执行验证资产库：单调剂量—响应，19 个资产时六倍（$\rho = 0.96$，3/3 种子）。**b**，跨会话经验在第 10 个会话将累计利润翻倍（2.0×，$P = 0.037$；每臂 $n = 10$）；该增益的 39% 为基准记忆化（图 3c）。**c**，推理时技术栈（三评委，$n = 40$）超越最强商业模型（$n = 14$）：¥532 对 ¥433，Mann–Whitney $P = 0.0015$，$d = 1.0$；单评委口径持平（¥438 对 ¥433）。箱体为四分位距；菱形为均值。

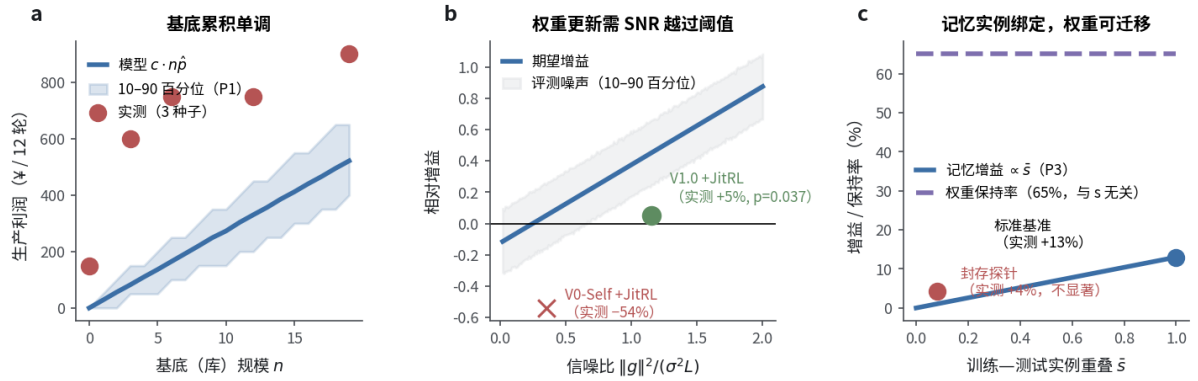


图 5 | 极简形式模型与实证对照。**a**，基底累积单调（模型期望与 10–90 百分位带；叠加实测剂量—响应）。**b**，权重更新需要信噪比越过阈值；阴影带为评测噪声；锚点为观测到的阈值以下（−54%）与阈值以上（+5%）系统。**c**，记忆收益随训练—测试重叠度 $\bar{s}$ 缩放；权重以与重叠无关的保持率迁移；点为观测到的同分布（+13%）与封存探针（+4%，不显著）收益。

无真人情况下的评委有效性：共识、偏差审计与执行骨架

本研究未做人类被试实验；我们以三项机器可审计的保障替代（图 6）。其一，对称跨厂商协议：在跨设计者、跨领域的 283 个完整评判三元组上，序数 Krippendorff $\alpha = 0.676$，两两 Spearman $\rho = 0.66$–0.74，对成交判定——经济体系实际定价的那个操作性决策——的一致率为 75–81%。其二，家族偏差审计：小米评委并不偏袒小米设计；其评分差（小米设计减去我们的设计）为 -0.61，自助法 95% 置信区间跨零，glm-5.3 为 -0.25（不显著）。其三，执行落地的骨架：CAD 合法性、交叠体积、包络超出、复用率与速度都是客观的几何内核数字，而本文的负结果仅凭这些指标即成立。一项如实的边界限定上述主张：轮评分跟踪的是感知精细度与需求符合度，而非几何精度——在从零设计轮内部，零件数与评分正相关（Spearman $\rho = +0.47$，$n = 49$），而跨轮型合并后相关性反转（$\rho = -0.63$），因为零件少的模块复用轮反而评分更高（扩展数据表 4）。本文的全部主张都关于这套体系定价的行为——该评委团下的成交判定——而非产品内在质量。语言模型评委的已知偏差——位置、冗长、自我增强[11]——恰恰是这套结构要中和的对象。

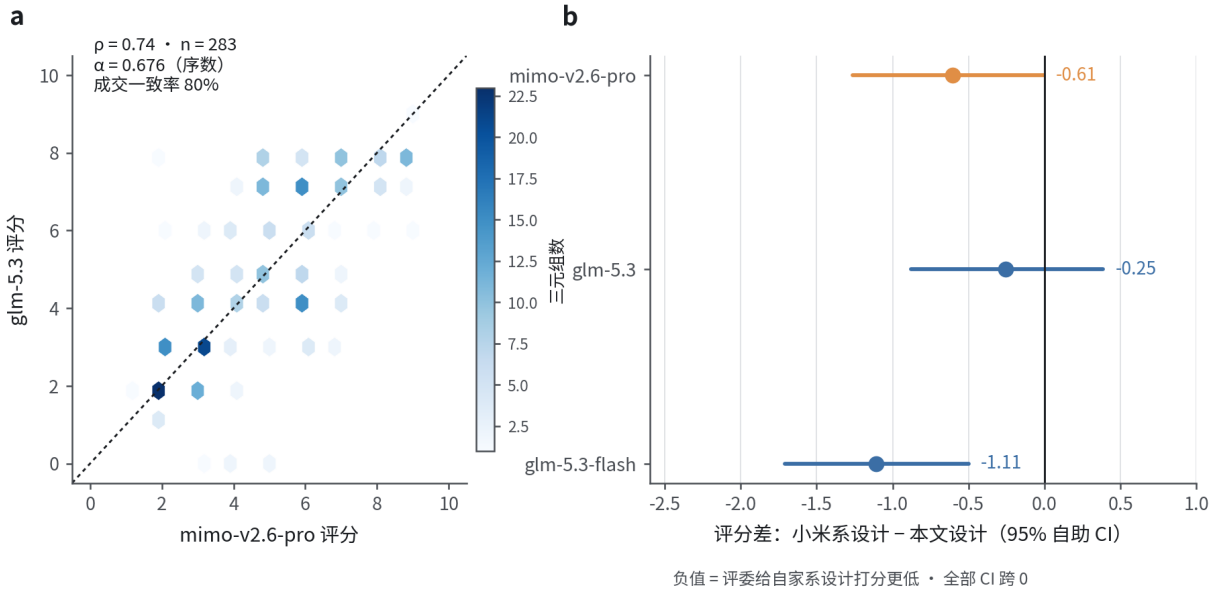


图 6 | 评委有效性审计。**a**，跨厂商评分一致（mimo-v2.6-pro 对 glm-5.3，283 个三元组；$\rho = 0.74$；$\alpha = 0.676$；成交一致率 80%）。**b**，家族偏差差值 ≤ 0，且每位评委的自助法 95% 置信区间均跨零。

讨论

Money Bench 上的改进有两个截然不同的来源，一组 2×2 对照将其分开（扩展数据表 3）。权重训练是大头：零样本基座均值仅 ¥30（中位 ¥0；25 轮仅 1 次成交），即便配上同一套推理时技术栈，未训练权重也只能到 ¥154（n = 5；25 轮中 6 轮成交），而不带任何栈的训练权重就有 ¥390。技术栈在训练权重之上叠加真实但次要的增益（单评委 ¥438，对称评审 ¥532）——两个因子可组合，权重在先。阈值以下，累积甚至会倒扣（弱自训模型上 −54%），同一阈值也划分任务领域。机制上顺理成章：验证是离散、无噪声的门，基底累积按构造单调；梯度步接受连续、带噪的增量，其漂移在实践者样本预算下无法越过评测噪声底。因此处方是关于边际回路的——用训练一次性跨过阈值，然后冻结权重、改进基底——它让端到端训练仅用一块消费级 GPU 的 90 亿参数开源模型，在对称、经家族偏差审计的协议下超过了最强商业系统。

三条边界让主张保持诚实。记忆是实例绑定的：在封存参数化探针上，回放优势消失（+4%，不显著），而权重保留 65%——记忆服务于车间内的复利，权重服务于跨域的触达。能力阈值是真实的：阈值以下，经验累积放大噪声（弱模型上 −54%），整个领域可以位于阈值以下。跨会话经验收益的 39% 是基准记忆化——由正则化度量，而非假设其不存在。

更宏观地说，Money Bench 贡献了一种评测哲学：用经济体系为行为定价，用物理执行加以验证，通过资本注册表使复利可观测，并像审计仪器一样审计评委。四要素皆可迁移到 CAD 之外：任何具有可执行造物的智能体领域——代码、文档、实验方案——都容纳同样的结构。尺子、失败、模型与数据全部开放。

方法

基准协议。每个会话运行五轮工作台产品族上的累积需求（手机座；封存探针实例从四个产品族、三种舱位类型、三种次级模块中采样，尺寸与桌面在固定区间内均匀采样；种子 20261005，从未用于训练）。第 1 轮为从零设计；第 2–5 轮要求适应、扩展、组合与压缩，后续需求明确要求复用早期模块。一个设计是 CSG JSON（workstation-csg/1：box、cylinder、union、difference、transform、capital）。真实执行：设计以 build123d 边界表示几何构建，导出 STEP，再导入并精确测量（交叠体积、相对桌面足迹的包络超出）。已执行的设计注册为资本资产（STEP 路径），后续轮次可通过 capital(asset_id) 导入。售出支付 ¥100 × 速度乘数（<10 s：1.5×；<30 s：1.2×；<60 s：1.0×；<120 s：0.8×；≥120 s：0.5×）；质量门为 0–10 满意度评分，评分 ≥ 5 成交。

评审。单评委协议：mimo-v2.6-pro 评分取中位数。三评委对称协议：mimo-v2.6-pro、glm-5.3 与 glm-5.3-flash 对相同设计评分取中位数。一致性统计基于 283 个完整评判三元组（序数 Krippendorff α、两两 Spearman、成交判定一致率）；家族偏差差值采用 2,000 次自助抽样的 95% 置信区间。轮评分跟踪感知精细度与需求符合度而非几何精度（评分—精细度审计；扩展数据表 4）。

模型与系统。39 个系统：6 个商业 API（mimo-v2.6-flash/pro、glm-5.3/-flash、deepseek-flash/v4-pro），21 个零样本开源模型（7 个利润非零；14 个因不遵守 schema 利润为 ¥0），12 个谱系条目。FluxEidos 谱系：qwen3.5-9b 基座（零样本 ¥30，中位 ¥0）→ 门控 SFT，约 150 个执行验证的自生成样本（¥260）→ CARE 自适应奖励强化学习——执行验证 CAD 奖励与 draft/improve/debug 混合域——单卡 RTX 4090D 上 QLoRA，12 次迭代（¥260 → ¥372–390）。第二代融合（CARE-v4）加入策略自身优于锚点轨迹上的错位加权自蒸馏（RISE 式 [37]）与黄金负样本轨迹上的余弦退火反思重试（ReflectRL 式 [36]），自 SFT 阶段再训 8 轮（扩展数据表 5）。注册门槛：任何已执行设计即注册为资本（v7 语义）；按评分注册的变体会在第 1 轮低于阈值时饿死后续轮（同一模型两种门槛下 ¥60 对 ¥390），故统一协议数字全部采用 v7 语义。V2 推理时技术栈运行于冻结的 V1.5 权重：R1 三选一候选按零件数再按交叠 CAD 筛选；自产评分 ≥6 设计的上下文内回放；语法修复；后期轮次带二次重试的条件性重采样；API 零分响应的评委重试。消融 v1→v7（每个 5–20 会话）逐一

隔离各机制。重采样歧义：26% 的轮次带有评分 < 5 的重采样产物；悲观/中性/乐观选择策略将三评委重算界定于 ¥489/532/564。

机制评测。权重级四类：权重自更新谱系；组内优势重分配（MiMo 式）；在线测试时强化学习；自蒸馏 SFT。资产库剂量—响应：冻结模型、固定参数化生产实例（4×3 轮），库跨代累积，3 个随机种子。经验库：优势加权的 logit 调制，记忆自空库跨会话累积，对照为无记忆组（每臂 $n = 10$）。记忆化分解：相似度筛除正则化拒绝相对当前基准实例自相似度 $\geq$ 阈值的记忆。

阈值对照。同一套推理时技术栈（R1 三选一 CAD 筛选、会话内资本复用、语法修复、带二次重试的条件性重采样、评委重试）原封不动跑在未训练的基座权重上（无 RL 适配器），$n = 5$ 会话，单评委协议。经验库自空库开始，仅累积本臂自身评分 ≥6 的设计（自采语义——V2 臂的库同样只采自其自身谱系的运行）。全部轮次的生成预算提高到 2,000 token（技术栈默认 R1 候选 900、后续轮 1,500），因为基座模型的格式化 JSON 在 900 token 处被截断；被截断掐死的对照测不出复用机制本身。零样本基线一格按标准本地模型协议重跑（2,048-token 预算、每轮双尝试、单评委重试加固）。

统计。如所声明采用双侧或单侧 Mann–Whitney U 检验；Cohen's d；Spearman ρ；序数 Krippendorff α；自助法 2,000 次抽样。除所报告的边界外未做多重比较校正；全部逐会话数据在代码仓库中。

可复现性。全部代码（基准、训练、推理栈、分析）、59 个结果数据集、逐次运行的会话产物、评委评分缓存与出图脚本均已开源。未涉及人类被试；全部评分由机器生成。

数据可用性全部基准代码、评测结果与数据集见 MechanogenesisBench 代码仓库。**代码可用性**基准、训练与推理栈代码与论文同仓库发布。**致谢**待补全。**作者贡献** E.W. 设计基准、运行全部实验并撰写论文。**利益冲突**作者声明无利益冲突。

参考文献

1. Zelikman, E., Wu, Y., Mu, J. & Goodman, N. D. 用推理自举推理：STaR。*Adv. Neural Inf. Process. Syst.* **35** (2022).
2. Yuan, W. 等. 自奖励语言模型。arXiv:2401.10020 (2024).
3. Singh, A. 等. 超越人类数据：以自训练扩展语言模型问题求解。arXiv:2312.06585 (2023).
4. DeepSeek-AI. DeepSeek-R1：以强化学习激励大语言模型的推理能力。*Nature* **645**, 633–638 (2025).
5. Shinn, N. 等. Reflexion：具备言语强化学习的语言智能体。*Adv. Neural Inf. Process. Syst.* **36** (2023).
6. Wang, G. 等. Voyager：基于大语言模型的开放式具身智能体。*Trans. Mach. Learn. Res.* (2024).
7. Packer, C. 等. MemGPT：让大语言模型充当操作系统。arXiv:2310.08560 (2023).
8. Park, J. S. 等. 生成式智能体：人类行为的交互式拟像。*Proc. UIST* (2023).
9. Jimenez, C. E. 等. SWE-bench：语言模型能解决真实 GitHub issue 吗? *Proc. ICLR* (2024).
10. Zhou, S. 等. WebArena：面向构建自主智能体的真实网页环境。*Proc. ICLR* (2024).
11. Zheng, L. 等. 用 MT-Bench 与 Chatbot Arena 评测“大模型当评委”。*Adv. Neural Inf. Process. Syst., Datasets Benchmarks* (2023).
12. Carlini, N. 等. 从大语言模型中提取训练数据。*Proc. USENIX Security* (2021).
13. Nasr, M. 等. 从（生产）语言模型规模化提取训练数据。arXiv:2311.17035 (2023).
14. Wu, R., Xiao, C. & Zheng, C. DeepCAD：面向计算机辅助设计模型的深度生成网络。*Proc. ICCV* (2021).
15. Khan, M. S. 等. Text2CAD：从自然语言描述生成序列式 CAD 模型。*Adv. Neural Inf. Process. Syst.* (2024).

16. Rukhovich, D. 等. CAD-Recode：从点云逆向工程 CAD 代码。arXiv:2412.14042 (2024).
17. Sun, Y. 等. 以自监督测试时训练应对分布偏移下的泛化。*Proc. ICML* (2020).
18. Akyürek, E. 等. 测试时训练的惊人有效性。arXiv 预印本 (2024).
19. Kirkpatrick, J. 等. 克服神经网络中的灾难性遗忘。*Proc. Natl Acad. Sci. USA* **114**, 3521–3526 (2017).
20. Parisi, G. I. 等. 神经网络的持续终身学习：综述。*Neural Networks* **113**, 54–71 (2019).
21. Christiano, P. 等. 来自人类偏好的深度强化学习。*Adv. Neural Inf. Process. Syst.* **30** (2017).
22. Ouyang, L. 等. 以人类反馈训练语言模型遵循指令。*Adv. Neural Inf. Process. Syst.* **35** (2022).
23. Wei, J. 等. 思维链提示激发大语言模型的推理。*Adv. Neural Inf. Process. Syst.* **35** (2022).
24. Wang, X. 等. 自洽性提升语言模型的思维链推理。*Proc. ICLR* (2023).
25. Yao, S. 等. ReAct：语言模型中推理与行动的协同。*Proc. ICLR* (2023).
26. Schick, T. 等. Toolformer：语言模型可以自学使用工具。*Adv. Neural Inf. Process. Syst.* **36** (2023).
27. 小米 MiMo 团队. MiMo-V2.6：开放推理模型（组内优势重分配）。模型卡与技术报告 (2026).
28. Brown, T. 等. 语言模型是少样本学习器。*Adv. Neural Inf. Process. Syst.* **33** (2020).
29. Kaplan, J. 等. 神经语言模型的缩放定律。arXiv:2001.08361 (2020).
30. Hu, E. 等. LoRA：大语言模型的低秩适配。*Proc. ICLR* (2022).
31. Dettmers, T. 等. QLoRA：量化大语言模型的高效微调。*Adv. Neural Inf. Process. Syst.* **36** (2023).
32. Cobbe, K. 等. 训练验证器求解数学应用题。arXiv:2110.14168 (2021).
33. Lightman, H. 等. 逐步验证。*Proc. ICLR* (2024).
34. Bommasani, R. 等. 基础模型的机遇与风险。arXiv:2108.07258 (2021).
35. Meta FAIR CodeGen 团队. Code World Model：用于代码生成世界模型研究的开放权重大语言模型。arXiv:2510.02387 (2025).
36. ReflectRL：经由反思到直推推理从黄金负轨迹学习。arXiv:2608.03972 (2026).
37. RISE：经由自外推策略蒸馏的递归改进。arXiv:2609.05295 (2026).

随本工作发布的改编方法来源：JitRL（arXiv:2601.18510 改编）、RRSI 正则化（arXiv:2609.24972 改编）。

扩展数据（摘要）

扩展数据图 1 | v1→v7 技术栈消融。各机制版本的平均利润(¥72 → ¥206 → ¥350 → ¥368 → ¥440/¥436)，每个 5–20 会话。

扩展数据图 2 | 机制对比。 CARE/GAR/TTRL/自蒸馏 SFT/技能库各臂的轮级成交率。

扩展数据图 3 | CAD 世界模型。预测适配器达到 92% 合法率、69% 精确评分；基于排序器的筛选用例为负结果(学习排序的修复已记录在案)。

扩展数据表 1 | 完整 39 系统排行榜，含协议、n 与逐次运行离散度（见代码仓库）。

扩展数据表 2 | 封存探针泛化。 V2 技术栈 ¥341 对纯权重 ¥327（每臂 $n = 10$）；轮级评分。

扩展数据表 3 | 阈值对照：2×2 因子设计。零样本基座均值 ¥30（中位 ¥0；$n = 5$, 25 轮中 1 轮成交；2,048-token 预算下 13/25 轮执行为合法 CAD——瓶颈不是输出格式而是设计质量）；基座 + 同一套推理时技术栈 ¥154（$n = 5$ 会话：240、150、80、150、150；25 轮中 6 轮成交；s.d. ¥57）；训练权重不带栈 ¥390；训练权重 + 栈 ¥438 单评委（¥532 三评委）。

扩展数据表 4 | 评分—精细度审计。 141 个无歧义轮次的零件数与轮评分：合并 Spearman $\rho = -0.63$（辛普森反转——从零轮为精细度定价，$\rho = +0.47$，$n = 49$；模块复用轮零件少却评分更高）。仓库数据：parts_rating_audit.json。

扩展数据表 5 | CARE-v4 融合（错位加权自蒸馏 + 反思失败轨迹）。 训练期 rollout 质量全程：成交率 0.25 → 0.375，合法率 0.79 → 0.94–0.99，平均评分 3.51 → 4.62（CARE-v3 单轮最佳：0.222 / 0.507 / 3.91）。同一统一协议（v7 注册、单评委、每臂 $n = 10$）的 Bench 对照：CARE-v4 ¥375（中位 ¥450；50 轮中 25 轮成交）对 CARE-v3 ¥330（中位 ¥300；22/50）；单侧 Mann–Whitney $P = 0.21$。同批设计的对称三厂商重算（记录的 mimo-v2.6-pro 加 glm-5.3 与 glm-5.3-flash，3 中位 ≥ 5 成交）：CARE-v3 ¥495（中位 ¥450）对 CARE-v4 ¥390（中位 ¥450），双侧 $P = 0.043$（留一法 0.008–0.035）——评委口径排序反转；成交数 CARE-v3 从 22 → 33/49，CARE-v4 仅 25 → 26/50。单评委即策略的训练奖励模型，且融合策略的设计显著更紧凑（具名零件 1.6 对 2.7；臂内评分—零件 $r = 0.81$）。执行门控口径（事后定义；成交 = 合法 CAD 且落在该轮桌面内，无评委；速度定价不变）：CARE-v4 十次会话每次 ¥750，对 CARE-v3 均值 ¥315（中位 ¥300；一次 ¥0），$P = 2\times10^{-5}$，$d = 4.7$——桌面适配 50/50 对 21/49（合并轮 0/10、收缩轮 0/9），自交零件对 0.80 对 2.86。评委口径与执行口径都予报告，皆不单独作真值。仓库数据：care_v4_headtohead_3judge.json、care_v4_execution_gated.json。

正文约 *3,300* 词（不含方法、参考文献与图注）。补充信息：命题 *P1–P3* 及证明；形式模型仿真代码。