机器制造模型的自我改进存在于基底之中，而非权重之中

Exuberant Witness [1]

[1] MechanogenesisBench 项目（单位信息待补全）

通信作者：通信作者邮箱待补全

摘要

大语言模型正越来越多地被用于设计物理造物，一个不断壮大的文献群正通过“经验”改进这类任务——在自生成数据上微调、在权重上做强化学习，或在冻结的模型周围积累记忆与技能。然而，改进究竟发生在何处，此前从未被度量。本文提出 Money Bench（货币基准），以经济学方式为该问题定价：在五轮累积式产品设计中，一个设计只有当它能够以真实计算机辅助设计几何执行（build123d 边界表示：构建、STEP 导出、再导入、精确测量）、满足充任客户的三厂商评委团、并且交付速度落入速度分层定价的付费档位时，才能赚到钱；每个已执行的设计随即注册为可导入的资本，供后续轮次使用——改进便像真实车间一样复利累积。在对 9 家厂商 39 个系统的评测中，我们发现：(1) 领域迁移令所有系统的收入崩塌，最强商业模型仅保留域内利润的 29–32%；(2) 在 90 亿参数规模上，我们测试的四类权重级自我改进全部无法改进已训练基线——因为重复评测的噪声底（相同权重下每会话 ±¥85）高于约 30 个样本的生成预算下单次更新的漂移量；(3) 跨会话经验收益的 39% 是基准记忆化——由筛除自相似记忆的正则化所揭示。一个极简形式模型解释了全部三项发现——经验证的基底单调累积、梯度更新继承信噪比阈值、记忆是实例绑定的——并给出明确处方：冻结权重。一个精选资产库令生产利润复利增长六倍，跨会话经验使其翻倍；一个五机制推理时技术栈在对称三厂商评审下，让 90 亿参数开源模型超越最强商业前沿模型（每会话 ¥532 对 ¥433，$P = 0.0015$，Cohen’s $d = 1.0$，$n = 40$），而训练算力仅约其千分之一。

引言

机器制造——设计必须可装配、可配合、可销售的物理造物——正在成为语言模型的任务。神经 CAD 生成已从操作序列 [14] 发展到文本条件设计 [15]，再到编写 CAD 代码的语言模型 [16]；执行验证型基准已成为评测编程智能体的标准 [9,10]。自然的下一个问题是经济学问题：当模型积累制造机器的经验时，系统是否赚到更多钱——收益究竟存在于权重、记忆，还是造物之中?

该领域的默认答案是权重。自训练回路将自生成解筛回微调 [1–3]；自奖励模型自举自身的偏好信号 [2]；强化学习直接塑造推理 [4]，其建立在偏好学习基础 [21] 与指令微调体系 [22] 之上，样本规模大得多。另一条平行路线改进的是系统而非参数：情景记忆中的言语反思 [5]、可执行技能库 [6]、操作系统式记忆管理 [7]、记忆流智能体 [8]；思维链提示与自洽性 [23,24] 证明了显著收益无需任何训练，工具使用与行动框架 [25,26] 则将其扩展到智能体。这两族方法很少在同一把尺子上比较，而现有 CAD 基准 [14–16] 度量的是单次静态质量，而非累积经济学。

本文提出 Money Bench, 为这一问题定价（图 1）。五轮累积需求——从零设计、适应、扩展、组合、压缩——驱动的设计必须以真实 build123d 边界表示几何执行，执行失败则一无所获。三厂商评委团模拟客户；售出支付 ¥100 × 速度乘数，越快越值钱；每一轮的合格设计注册为可导入的资本——免费且快于重建。复利是可度量、可归因、可审查的。在对 9 家厂商 39 个系统的评测中（图 2），我们得到三项结果（图 3）：领域迁移令所有系统的收入崩塌；90 亿参数规模的权重级自我改进被噪声主导，我们测试的四类方法全部从已训练基线倒退；测试时经验收益的 39% 是基准记忆化。一个极简形式模型统一三者（图 5）：经验证基底的累积单调且无阈值，梯度更新继承信噪比阈值，记忆随训练—测试实例重叠度缩放。模型的处方——冻结权重、改进基底——使我们的 90 亿参数系统在对称评审下超越商业前沿（图 4），边界条件如实报告（图 5c，见结果）。



图 1 | Money Bench 闭环。五轮累积需求驱动语言模型输出 workstation-csg JSON，该设计必须以真实 build123d 边界表示几何执行（构建 → STEP 导出 → 再导入 → 精确测量）；合格设计由三厂商评委团评分（中位数决定成交，¥100 × 速度乘数）；每个已执行的设计注册为可导入资本——免费且快于重建——供后续轮次使用。改进通过资本注册表复利累积，而不是通过模型。

结果

领域迁移令所有系统的收入崩塌

在两个未见过的任务域——机械加工夹具设计与生产线布局——上，每个系统的收入都大幅下降（图 3a；三评委协议，每格 $n = 5$ 会话）。最强商业模型仅保留域内利润的 29%（夹具）与 32%（布局）（¥433 → ¥124 与 ¥138）。我们的纯权重模型呈同一定性模式（¥390 → ¥0 与 ¥60；表 1）。这把尺子暴露的是领域难度现象，而非某个模型的个别弱点。

表 1 | 多领域利润（¥/会话，三评委中位数，n = 5）

系统	工作台（域内）	夹具	布局
mimo-v2.6-flash	433	124	138
FluxEidosV1.5（本文）	390	0	60
FluxEidosV2（本文）	532	0	**264**

权重级自我改进在 90 亿参数规模被噪声主导

从已训练基线（FluxEidosV1.0，¥372–387）出发，四类权重级自我改进全部倒退或停滞（图 3b）：权重自更新谱系降至 ¥210（−44%，且其探针收益不迁移）；组内优势重分配 [27] 在学习率 2×10^{-5} 时降至 ¥270，并伴随格式遗忘（有效设计在三代内从 33/36 跌至 1/36）；在线测试时强化学习 [17,18] 降至 ¥270；自蒸馏微调则因格式污染崩塌至 ¥0。根因可被度量：相同权重的重复评测在十次探针会话中跨越 ¥38–225（$n = 10$，±1 s.d. ≈ ¥85），而每一代强化学习只携带约 30 个设计。在这样的样本预算下，单次更新的漂移无法越过评测噪声底——经典干扰问题 [19,20] 在语言模型规模上的样本预算面孔。那些著名的自训练成功案例 [1–3]，样本量高出四到六个数量级。

测试时经验收益的 39% 是基准记忆化

跨会话经验累积（优势加权记忆库，JitRL 式；见方法）使相同权重的利润翻倍（¥195 → ¥390，$P = 0.037$；图 4b）。以“记忆与基准实例的相似度”筛除记忆的正则化（RRSI 式；见方法）拒绝了在基准需求上检索到的 21 条记忆中的全部 21 条（自相似度 = 1.0）。分解如下（图 3c）：¥240 诚实泛化 + ¥150 基准记忆化——这是训练数据记忆化 [12,13] 在评测侧的对应物，在此被度量、被正则化、并被排除在泛化主张之外。

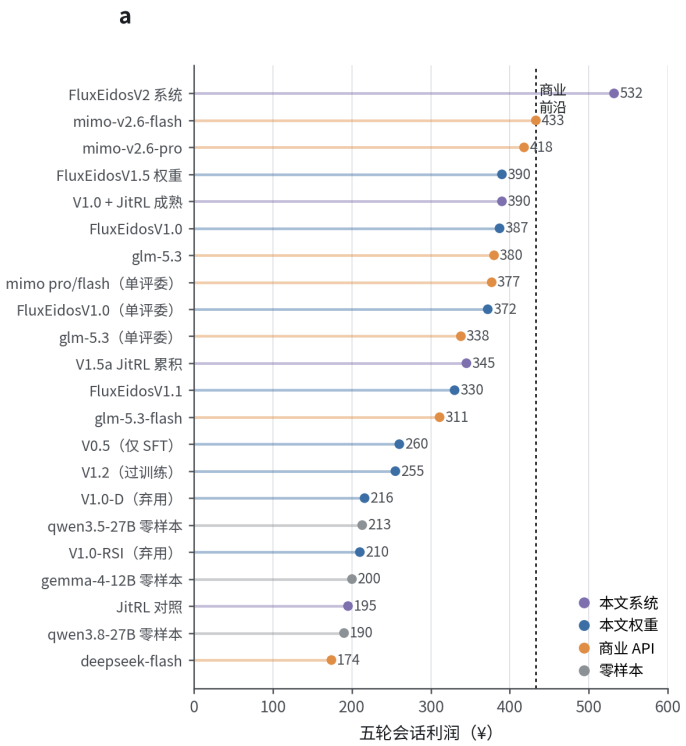


图 2 | 主排行榜。39 个系统在五轮会话中的利润：本文系统条目（紫色）与本文权重（蓝色），对照商业 API（橙色）与零样本开源模型（灰色）；14 个利润为 ¥0 的零样本系统因篇幅省略。虚线标出商业前沿。除标注外均为单评委协议；各系统 n 见排行榜数据。

经验证的基底复利累积

权重冻结后，改进存在于三种基底之中（图 4）。其一，执行验证资产的精选库：每 12 轮的生产利润随库规模单调上升——0、3、6、12、19 个资产对应 ¥150、600、750、750、900（Spearman ρ = 0.96；3/3 随机种子单调；图 4a）。资产即 STEP 文件：验证一次，永不遗忘，复用免费且快速——速度定价直接奖励它们。其二，跨会话经验在第 10 个会话将利润翻倍（图 4b）。其三，同一套冻结权重上的五机制推理时技术栈——按结构细节 CAD 筛选的三选一候选生成、系统自产评分 ≥6 设计的上下文内回放、语法修复层、条件性重采样、评委重试——每个机制经消融逐一隔离（每个版本 5–20 会话；见方法）。

完整技术栈在对称评审下超越商业前沿

在对称三厂商协议下（mimo-v2.6-pro、glm-5.3 与 glm-5.3-flash 对相同设计评分取中位数），技术栈每会话赚取 ¥532（中位数 ¥540，$n = 40$），最强商业模型为 ¥433（$n = 14$）：+23%，Mann–Whitney $P = 0.0015$，Cohen’s $d = 1.0$（图 4c）。重采样歧义边界（悲观 ¥489 至乐观 ¥564；见方法）全部高于前沿。在单评委协议下，同一批会话赚取 ¥438——持平（$P = 0.39$）——因为单评委系统性地把我们的设计压在成

交阈值附近，而 glm 评委不会；下方的家族偏差审计表明这是评委宽严结构，而非厂商俘获，且对称协议对每个系统一视同仁。技术栈还直接赢下布局域（¥264 对 ¥138，$P = 0.029$；表 1）——基底机制在模型高于能力阈值之处皆可迁移。成本：一块消费级 GPU，训练算力约为前沿模型的千分之一，起点是一个零样本赚取 ¥0 的基座模型。

极简形式模型及其处方的适用边界

三个命题组织起全部发现（图 5；证明见补充信息）。**(P1) 基底单调性：**若资产仅在执行验证后入库，累积价值 $V(n) = c \cdot \mathrm{Binomial}(n, p)$ 在期望上单调，对能力 p 没有阈值。**(P2) 权重更新阈值：**一步 $\Delta\theta = \eta(g + \varepsilon)$（噪声方差 σ^2、零均值）使真实性能改变 $\eta\|g\|^2 - \eta^2\sigma^2 L/2$；观测到的改进还会被评测噪声掩蔽，因此只有越过信噪比阈值才能检出改进——这是一个基底所没有的能力阈值。**(P3) 记忆实例绑定：**回放收益随训练—测试重叠度 $\bar{s}$ 缩放，而权重级能力以与重叠无关的保持率迁移。每项预测均被验证：剂量—响应 $\rho = 0.96$（图 5a）；阈值以下的经验累积放大噪声（弱模型上 -54%，阈值以上 $+5\%$，$P = 0.037$；图 5b）；同分布回放收益 $+13\%$，而封存探针收益 $+4\%$（不显著，$P = 0.40$），权重保留 65% 的域内利润（图 5c）。阈值同样划分领域——夹具位于阈值以下（各轮评分 2.4–3.6；没有任何设计达到 6，故该域的经验库从未累积），布局位于阈值以上。记忆在同分布内取胜；权重在跨域时取胜；两种基底的迁移画像互不相交。

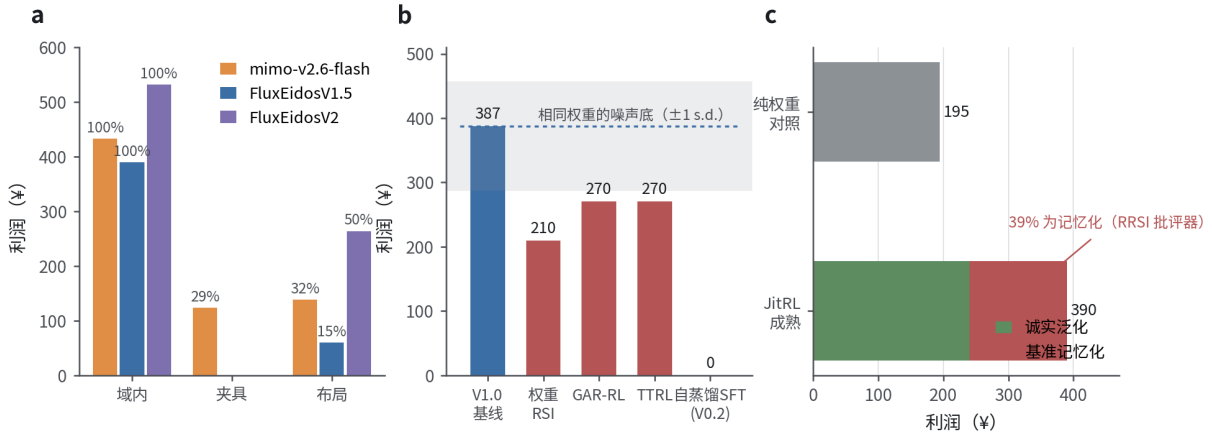


图 3 | 三项发现。**a**，领域迁移使每个系统退化；前沿模型保留域内利润的 29–32%（三评委，每格 $n = 5$）。**b**，四类权重级自我改进跌至已训练基线之下、并落入相同权重的噪声底之内（灰带，重复评测 ±1 s.d.，$n = 10$）。**c**，跨会话经验收益分解为诚实泛化（¥240）与基准记忆化（¥150，39%），经相似度筛除正则化揭示。

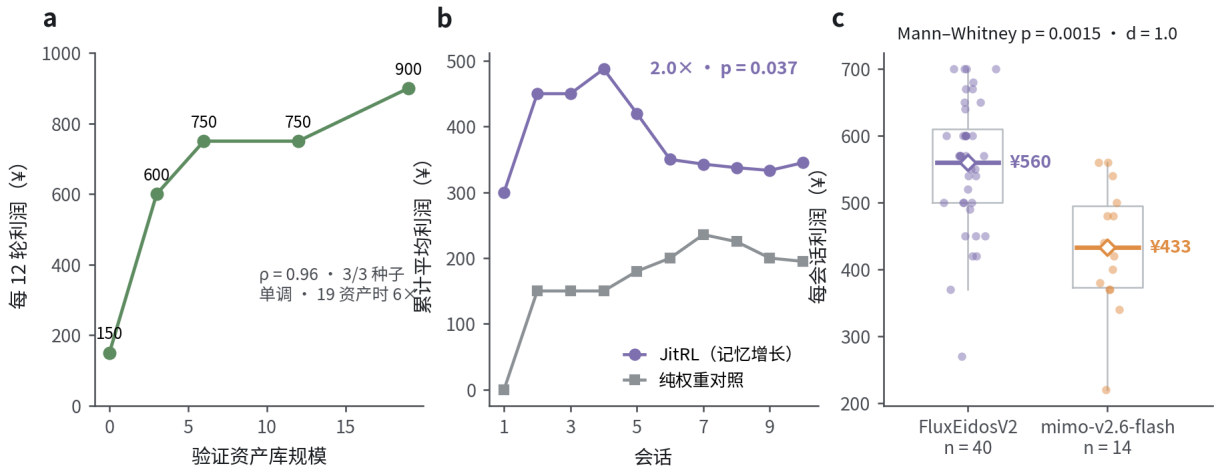


图 4 | 基底复利累积。**a**，执行验证资产库：单调剂量—响应，19 个资产时六倍（ρ = 0.96，3/3 种子）。**b**，跨会话经验在第 10 个会话将累计利润翻倍（2.0×，$P = 0.037$；每臂 $n = 10$）。**c**，推理时技术栈（三评委，$n = 40$）超越最强商业模型（$n = 14$）：¥532 对 ¥433，Mann–Whitney $P = 0.0015$，$d = 1.0$。箱体为四分位距；菱形为均值。

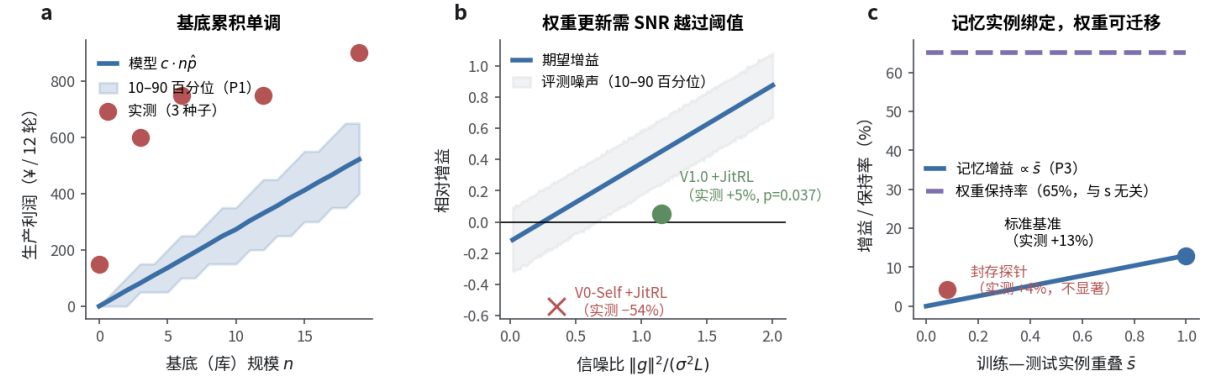


图 5 | 极简形式模型与实证对照。**a**，基底累积单调（模型期望与 10–90 百分位带；叠加实测剂量—响应）。**b**，权重更新需要信噪比越过阈值；阴影带为评测噪声；锚点为观测到的阈值以下（−54%）与阈值以上（+5%）系统。**c**，记忆收益随训练—测试重叠度 $\bar{s}$ 缩放；权重以与重叠无关的保持率迁移；点为观测到的同分布（+13%）与封存探针（+4%，不显著）收益。

无真人情况下的评委有效性：共识、偏差审计与执行骨架

本研究未做人类被试实验；我们以三项机器可审计的保障替代（图 6）。其一，对称跨厂商协议：在跨设计者、跨领域的 283 个完整评判三元组上，序数 Krippendorff α = 0.676，两两 Spearman ρ = 0.66–0.74，对成交判定——经济体系实际定价的那个操作性决策——的一致率为 75–81%。其二，家族偏差审计：小米评委并不偏袒小米设计；其评分差（小米设计减去我们的设计）为 −0.61，自助法 95% 置信区间跨零，glm-5.3 为 −0.25（不显著）。其三，执行落地的骨架：CAD 合法性、交叠体积、包络超出、复用率与速度都是客观的几何内核数字，而本文的负结果仅凭这些指标即成立。语言模型评委的已知偏差——位置、冗长、自我增强 [11]——恰恰是这套结构要中和的对象。

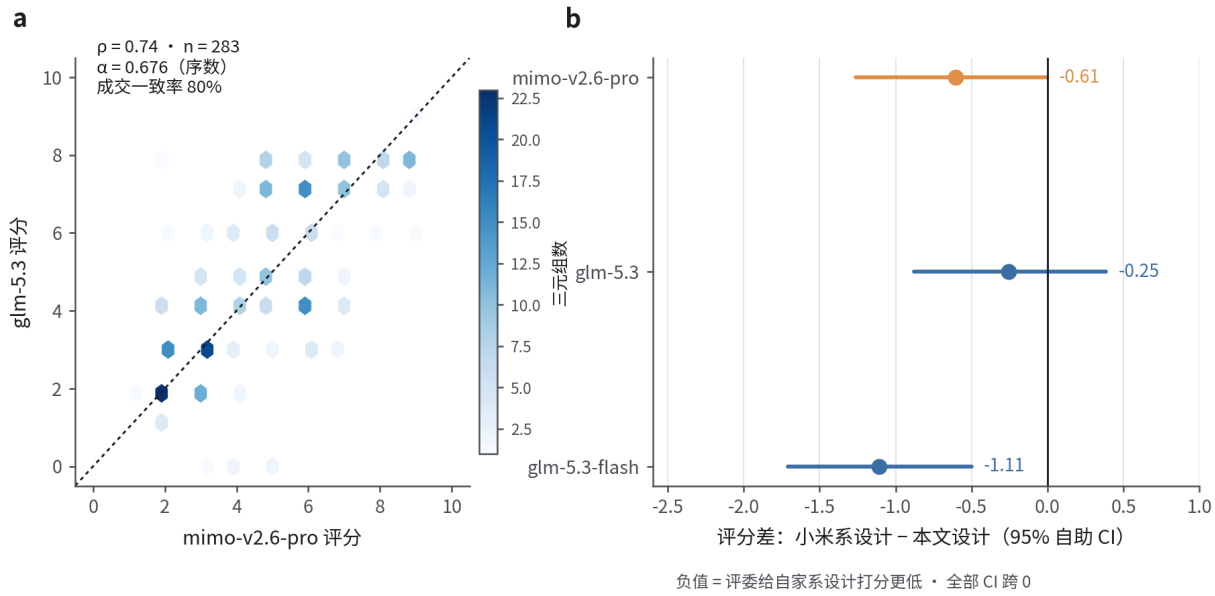


图 6 | 评委有效性审计。**a**，跨厂商评分一致（mimo-v2.6-pro 对 glm-5.3，283 个三元组；ρ = 0.74；α = 0.676；成交一致率 80%）。**b**，家族偏差差值 ≤ 0，且每位评委的自助法 95% 置信区间均跨零。

讨论

在 Money Bench 上能够复利累积的自我改进存在于经验证的基底——资产、经验与选择——而非 90 亿参数规模的权重更新；后者在能力阈值以下被噪声主导，而该阈值同样划分任务领域。这一发现有自然的机制：验证是离散、无噪声的门，因此基底累积按构造单调；而梯度步接受连续、带噪的增量，其漂移在实践者样本预算下无法越过评测噪声底。处方——冻结权重、改进基底——以千分之一的训练算力，让一个 90 亿参数开源模型在对称、经家族偏差审计的协议下超过了最强商业系统。

三条边界让主张保持诚实。记忆是实例绑定的：在封存参数化探针上，回放优势消失（+4%，不显著），而权重保留 65%——记忆服务于车间内的复利，权重服务于跨域的触达。能力阈值是真实的：阈值以下，经验累积放大噪声（弱模型上 −54%），整个领域可以位于阈值以下。跨会话经验收益的 39% 是基准记忆化——由正则化度量，而非假设其不存在。

更宏观地说，Money Bench 贡献了一种评测哲学：用经济体系为行为定价，用物理执行加以验证，通过资本注册表使复利可观测，并像审计仪器一样审计评委。四要素皆可迁移到 CAD 之外：任何具有可执行造物的智能体领域——代码、文档、实验方案——都容纳同样的结构。尺子、失败、模型与数据全部开放。

方法

基准协议。每个会话运行五轮工作台产品族上的累积需求（手机座；封存探针实例从四个产品族、三种舱位类型、三种次级模块中采样，尺寸与桌面在固定区间内均匀采样；种子 20261005，从未用于训练）。第 1 轮为从零设计；第 2–5 轮要求适应、扩展、组合与压缩，后续需求明确要求复用早期模块。一个设计是 CSG JSON（workstation-csg/1：box、cylinder、union、difference、transform、capital）。真实执行：设计以 build123d 边界表示几何构建，导出 STEP，再导入并精确测量（交叠体积、相对桌面足迹的包络超出）。已执行的设计注册为资本资产

(STEP 路径), 后续轮次可通过 capital(asset_id) 导入。售出支付 ¥100 × 速度乘数 (<10 s: 1.5×; <30 s: 1.2×; <60 s: 1.0×; <120 s: 0.8×; ≥120 s: 0.5×); 质量门为 0–10 满意度评分, 评分 ≥ 5 成交。

评审。单评委协议: mimo-v2.6-pro 评分取中位数。三评委对称协议: mimo-v2.6-pro、glm-5.3 与 glm-5.3-flash 对相同设计评分取中位数。一致性统计基于 283 个完整评判三元组 (序数 Krippendorff α、两两 Spearman、成交判定一致率); 家族偏差差值采用 2,000 次自助抽样的 95% 置信区间。

模型与系统。39 个系统: 6 个商业 API (mimo-v2.6-flash/pro、glm-5.3/-flash、deepseek-flash/v4-pro), 21 个零样本开源模型 (7 个利润非零; 14 个因不遵守 schema 利润为 ¥0), 12 个谱系条目。FluxEidos 谱系: qwen3.5-9b 基座 (零样本 ¥0) → 门控 SFT, 约 150 个执行验证的自生成样本 (¥260) → CARE 自适应奖励强化学习, 单卡 RTX 4090D 上 QLoRA, 12 次迭代 (¥372–390)。V2 推理时技术栈运行于冻结的 V1.5 权重: R1 三选一候选按零件数再按交叠 CAD 筛选; 自产评分 ≥6 设计的上下文内回放; 语法修复; 后期轮次带二次重试的条件性重采样; API 零分响应的评委重试。消融 v1→v7 (每个 5–20 会话) 逐一隔离各机制。重采样歧义: 26% 的轮次带有评分 < 5 的重采样产物; 悲观/中性/乐观选择策略将三评委重算界定于 ¥489/532/564。

机制评测。权重级四类: 权重自更新谱系; 组内优势重分配 (MiMo 式); 在线测试时强化学习; 自蒸馏 SFT。资产库剂量—响应: 冻结模型、固定参数化生产实例 (4 × 3 轮), 库跨代累积, 3 个随机种子。经验库: 优势加权的 logit 调制, 记忆自空库跨会话累积, 对照为无记忆组 (每臂 $n = 10$)。记忆化分解: 相似度筛除正则化拒绝相对当前基准实例自相似度 ≥ 阈值的记忆。

统计。如所声明采用双侧或单侧 Mann–Whitney U 检验; Cohen's d; Spearman ρ; 序数 Krippendorff α; 自助法 2,000 次抽样。除所报告的边界外未做多重比较校正; 全部逐会话数据在代码仓库中。

可复现性。全部代码 (基准、训练、推理栈、分析)、59 个结果数据集、逐次运行的会话产物、评委评分缓存与出图脚本均已开源。未涉及人类被试; 全部评分由机器生成。

数据可用性全部基准代码、评测结果与数据集见 MechanogenesisBench 代码仓库。**代码可用性**基准、训练与推理栈代码与论文同仓库发布。**致谢**待补全。**作者贡献** E.W. 设计基准、运行全部实验并撰写论文。**利益冲突**作者声明无利益冲突。

参考文献

1. Zelikman, E., Wu, Y., Mu, J. & Goodman, N. D. 用推理自举推理: STaR。*Adv. Neural Inf. Process. Syst.* **35** (2022).
2. Yuan, W. 等. 自奖励语言模型。arXiv:2401.10020 (2024).
3. Singh, A. 等. 超越人类数据: 以自训练扩展语言模型问题求解。arXiv:2312.06585 (2023).
4. DeepSeek-AI. DeepSeek-R1: 以强化学习激励大语言模型的推理能力。*Nature* **645**, 633–638 (2025).
5. Shinn, N. 等. Reflexion: 具备言语强化学习的语言智能体。*Adv. Neural Inf. Process. Syst.* **36** (2023).
6. Wang, G. 等. Voyager: 基于大语言模型的开放式具身智能体。*Trans. Mach. Learn. Res.* (2024).
7. Packer, C. 等. MemGPT: 让大语言模型充当操作系统。arXiv:2310.08560 (2023).
8. Park, J. S. 等. 生成式智能体: 人类行为的交互式拟像。*Proc. UIST* (2023).
9. Jimenez, C. E. 等. SWE-bench: 语言模型能解决真实 GitHub issue 吗? *Proc. ICLR* (2024).
10. Zhou, S. 等. WebArena: 面向构建自主智能体的真实网页环境。*Proc. ICLR* (2024).
11. Zheng, L. 等. 用 MT-Bench 与 Chatbot Arena 评测 "大模型当评委"。*Adv. Neural Inf. Process. Syst., Datasets Benchmarks* (2023).
12. Carlini, N. 等. 从大语言模型中提取训练数据。*Proc. USENIX Security* (2021).

13. Nasr, M. 等. 从（生产）语言模型规模化提取训练数据。arXiv:2311.17035 (2023).
14. Wu, R., Xiao, C. & Zheng, C. DeepCAD: 面向计算机辅助设计模型的深度生成网络。*Proc. ICCV* (2021).
15. Khan, M. S. 等. Text2CAD: 从自然语言描述生成序列式 CAD 模型。*Adv. Neural Inf. Process. Syst.* (2024).
16. Rukhovich, D. 等. CAD-Recode: 从点云逆向工程 CAD 代码。arXiv:2412.14042 (2024).
17. Sun, Y. 等. 以自监督测试时训练应对分布偏移下的泛化。*Proc. ICML* (2020).
18. Akyürek, E. 等. 测试时训练的惊人有效性。arXiv 预印本 (2024).
19. Kirkpatrick, J. 等. 克服神经网络中的灾难性遗忘。*Proc. Natl Acad. Sci. USA* **114**, 3521–3526 (2017).
20. Parisi, G. I. 等. 神经网络的持续终身学习：综述。*Neural Networks* **113**, 54–71 (2019).
21. Christiano, P. 等. 来自人类偏好的深度强化学习。*Adv. Neural Inf. Process. Syst.* **30** (2017).
22. Ouyang, L. 等. 以人类反馈训练语言模型遵循指令。*Adv. Neural Inf. Process. Syst.* **35** (2022).
23. Wei, J. 等. 思维链提示激发大语言模型的推理。*Adv. Neural Inf. Process. Syst.* **35** (2022).
24. Wang, X. 等. 自洽性提升语言模型的思维链推理。*Proc. ICLR* (2023).
25. Yao, S. 等. ReAct: 语言模型中推理与行动的协同。*Proc. ICLR* (2023).
26. Schick, T. 等. Toolformer: 语言模型可以自学使用工具。*Adv. Neural Inf. Process. Syst.* **36** (2023).
27. 小米 MiMo 团队. MiMo-V2.6: 开放推理模型（组内优势重分配）。模型卡与技术报告 (2026).
28. Brown, T. 等. 语言模型是少样本学习器。*Adv. Neural Inf. Process. Syst.* **33** (2020).
29. Kaplan, J. 等. 神经语言模型的缩放定律。arXiv:2001.08361 (2020).
30. Hu, E. 等. LoRA: 大语言模型的低秩适配。*Proc. ICLR* (2022).
31. Dettmers, T. 等. QLoRA: 量化大语言模型的高效微调。*Adv. Neural Inf. Process. Syst.* **36** (2023).
32. Cobbe, K. 等. 训练验证器求解数学应用题。arXiv:2110.14168 (2021).
33. Lightman, H. 等. 逐步验证。*Proc. ICLR* (2024).
34. Bommasani, R. 等. 基础模型的机遇与风险。arXiv:2108.07258 (2021).
35. Meta FAIR CodeGen 团队. Code World Model: 用于代码生成世界模型研究的开放权重大语言模型。arXiv:2510.02387 (2025).

随本工作发布的改编方法来源：JitRL（arXiv:2601.18510 改编）、RRSI 正则化（arXiv:2609.24972 改编）。

扩展数据（摘要）

扩展数据图 1 | v1→v7 技术栈消融。各机制版本的平均利润(¥72 → ¥206 → ¥350 → ¥368 → ¥440/¥436)，每个 5–20 会话。

扩展数据图 2 | 机制对比。 CARE/GAR/TTRL/自蒸馏 SFT/技能库各臂的轮级成交率。

扩展数据图 3 | CAD 世界模型。预测适配器达到 92% 合法率、69% 精确评分；基于排序器的筛选用例为负结果(学习排序的修复已记录在案)。

扩展数据表 1 | 完整 39 系统排行榜，含协议、n 与逐次运行离散度（见代码仓库）。

扩展数据表 2 | 封存探针泛化。 V2 技术栈 ¥341 对纯权重 ¥327（每臂 $n = 10$）；轮级评分。

正文约 $3{,}300$ 词（不含方法、参考文献与图注）。补充信息：命题 $P1$–$P3$ 及证明；形式模型仿真代码。